تقييم حدود الثقة في **MCP Apps:** دراسة تجريبية للقدرات التي يديرها المضيف

Evaluating Trust Boundaries in MCP Apps: An Experimental Study of Host-Mediated Capabilities

الباحثون: أ.د.ب. مالك ناصر علي الجبري، مبارك وليد الحمادي، ياسين عبد العزيز الخالقي، محمد سيف علي الحيمي

الجهة: كلية الحاسوب وتكنولوجيا المعلومات، الجامعة الإماراتية الدولية، صنعاء

التاريخ: سبتمبر 2026م

الملخص الأكاديمي **(Abstract)**

الملخص الأكاديمي — يُعد بروتوكول سياق النموذج (Model Context Protocol - MCP) معيارًا صناعيًا متقدمًا لربط وكلاء النماذج اللغوية الكبيرة (LLM) امتداد MCP Apps** بمصادر البيانات والأدوات الخارجية. ويُقدم **MCP نقلة نوعية عبر تمكين خوادم MCP من تقديم واجهات مستخدم رسومية وتفاعلية (SEP-1865) معيار وفق الحديث. وعلى الرغم من أن المواصفة القياسية تفرض أن تُعرض مباشرة داخل تطبيق المضيف (Conversational Host Client)، وسياسات أمان المحتوى (CSP)، عزلًا تقنيًا إلزاميًا للواجهة باستخدام إطارات العمل المعزولة (Sandboxed Iframes)، إلا أنها تُحيل إدارة القدرات التي يديرها المضيف **(Host-Mediated Capabilities)**—وعلى وجه التحديد: فتح الروابط الخارجية (ui/open-link)، وحقن رسائل المحادثة (ui/message)، وتعديل سياق النموذج (ui/update-model-context)—إلى القرارات والسياسات التقديرية للمضيف.

تُقدم هذه الورقة، في حدود ما وصل إليه علمنا، أول دراسة تجريبية لقياس حد الثقة الفاصل بين ما يمنعه العزل التقني للمتصفح وما يجب أن يضبطه المضيف بسياساته. ونُثبت عمليًا أن المضيف الملتزم بالمواصفة القياسية (Baseline)، ورغم نجاحه في منع الوصول المباشر إلى الصفحة والشبكة غير المصرح بها، يسمح للواجهات غير الموثوقة بتسريب البيانات الحساسة (SYNTHETIC_SECRET_001) في سياق النموذج دون طلب أي موافقة صريحة من المستخدم.

لمعالجة هذه الفجوة الأمنية، قمنا بتصميم وبناء وتقييم طبقة سياسة على جانب المضيف تعمل وفق أربع قواعد: حتمية (Scheme Validation)، تحقق من مخطط بروتوكول الروابط وتحديد حجم الرسائل (بحد أقصى 4 كيلوبايت)، وبوابة موافقة صريحة من المستخدم (User Consent Gate)، وشارة مرئية دائمة لتوضيح مصدر الواجهة. وفرت 180 نقطة قياس لزمن الاستجابة عبر متصفح (Chromium)، ومن خلال بيئة اختبار آلية تضمنت 41 تشغيلًا تجريبيًا أثبتت طبقة السياسة فاعليتها في خفض العمليات الحساسة المنفذة دون موافقة من 15/15 إلى 0/15، ومنع تسريب القيمة السرية بنسبة 100%، مع إثبات الحفاظ على المنفعة الوظيفية لجميع القنوات الثلاث

كما أظهرت سجلات التدقيق الداخلي عبر كافة القنوات .(n=1) التي يديرها المضيف في تجربة تأكيدية مخصصة المعترضة (410 أحداث تدقيق) أن فحص السياسة يضيف عبئًا زمنيًا وسيطًا قدره ≥ 0.1 مللي ثانية (0.0 مللي ثانية للأدوات والروابط، و0.1 مللي ثانية للرسائل وتحديث السياق؛ بمتوسط 0.06 مللي ثانية، وحد أقصى 1.6 مللي ثانية أثناء معالجة حمولات السياق المتداخلة)، وهو ما يقل كثيرًا عن العتبة التشغيلية المحددة بـ 20 مللي ثانية. تؤكد هذه النتائج صحة الفرضيات البحثية الثلاث (H1 قبول وH2 وH3) وتضع معايير واضحة لهندسة مضيفات MCP الآمنة.

الكلمات المفتاحية — بروتوكول سياق النموذج (MCP)، تطبيقات MCP Apps، القدرات، أمن وكلاء الذكاء الاصطناعي، العزل البرمجي، حدود الثقة، حقن الأوامر غير المباشر، التي يديرها المضيف.

1. المقدمة (Introduction)

من توليد النصوص المجردة إلى تنفيذ سلاسل الإجراءات المستقلة (LLMs) مع تحول وكلاء النماذج اللغوية الكبيرة برزت الحاجة إلى بروتوكولات معيارية للربط بين النماذج والبيئات البرمجية الخارجية. (Autonomous Workflows)، المعيار الأبرز الذي نظم قنوات استدعاء الأدوات وتصفح الموارد بين العميل (MCP) ويُعد بروتوكول سياق النموذج والخوادم المتعددة (Hou et al., 2025; Model Context Protocol, 2026b).

وعلى الرغم من كفاءة بروتوكول MCP، إلا أن تفاعل الأدوات ظل محصورًا في تبادل النصوص وهياكل JSON؛ فعند استدعاء أداة خارجية، يُعاد الناتج كنص يُحقن في سياق النموذج. واجهت هذه الآلية قصورًا كبيرًا في المهام التي تتطلب تفاعلًا بصريًا مثل الرسوم البيانية، والخرائط التفاعلية، ونماذج المحاكاة المالية. ولمعالجة ذلك، أُطلق امتداد **SEP-1865 (MCP Apps)** الذي يُمكّن خادم MCP من إرجاع واجهة ويب تفاعلية كاملة (HTML/JS/CSS) يعرضها المضيف داخل إطار معزول بالتوازي مع مجرى المحادثة (Salomon et al., 2026).

1.1 مشكلة حد الثقة (The Trust Boundary Problem)

يؤدي إدخال واجهات ويب ديناميكية إلى تغيير جوهري في النموذج الأمني للوكيل؛ فالواجهة التفاعلية ليست صفحة ثابتة، بل تطبيق نشط يتواصل مع المضيف ذهابًا وإيابًا عبر بروتوكول JSON-RPC المنقول بواسطة رسائل postMessage.

تحدد مواصفة MCP Apps مستويين من الحماية:

1. **العزل التقني الإلزامي (MUST):** يُلزم المضيف بعرض الواجهة داخل عنصر iframe مقيد الصلاحيات (sandbox="allow-scripts allow-same-origin allow-forms") وتطبيق سياسة أمان محتوى (CSP) تمنع الاتصال بأي

لا (tools/call) كما تُلزم برفض أي استدعاء أداة. (connectDomains) نطاق لم يُعلن عنه مسبقًا في بيانات الخادم

("app"). تتضمن وسام الرؤية الخاص بالتطبيقات

2. تُزود المواصفة الواجهة بقنوات رسمية لطلب **(Host-Mediated Capabilities)**: القدرات التي يديرها المضيف إجراءات ينفذها المضيف نيابة عنها:

- ui/open-link: مطالبة المضيف بفتح رابط خارجي في متصفح النظام.

- ui/message: إرسال رسالة مباشرة إلى مجرى محادثة المستخدم مع الوكيل.

- ui/update-model-context: تحديث أو تزويد سياق النموذج بمعلومات جديدة تؤثر على استجابات الذكاء الاصطناعي اللاحقة.

تكمن الفجوة الأمنية في أن المواصفة تنص على أن المضيف قد يطلب موافقة المستخدم أو يطبق سياسات محلية، ولكنها لا تفرض سلوكًا افتراضيًا صارمًا. وبالتالي، فإن المضيف الملتزم بالمواصفة القياسية الأساسية (Baseline)—الذي يطبق العزل التقني دون إضافة طبقة حوكمة—يقوم بتنفيذ هذه الطلبات تلقائيًا فور وصولها، مما يُشكل ثغرة هيكلية لاستغلال الصلاحيات.



الشكل 1: نظرة مفاهيمية لحد الثقة الفاصل بين مضيف المحادثة وتطبيقات *MCP Apps*، يوضح ضوابط العزل الإلزامية وفجوات الحوكمة التقديرية.

1.2 الأسئلة البحثية

تسعى هذه الدراسة للإجابة عن التساؤلات التالية:

- **SP1:** كيف يمكن التحقق عمليًا من التزام المضيف بحدود العزل الإلزامية (CSP ورؤية الأدوات)؟
- **SP2:** ما مدى قدرة تطبيق MCP غير موثوق على استغلال القنوات المسموحة (ui/open-link, ui/message, ui/update-model-context) لتسريب قيمة حساسة (SYNTHETIC_SECRET_001) أو تسميم السياق دون كسر العزل؟
- **SP3:** هل تنجح طبقة سياسة صغيرة على جانب المضيف في سد هذه الفجوة دون تعطيل الاستخدام المشروع ودون إضافة عبء زمني محسوس؟

2. الدراسات السابقة (Related Work)

حظي أمن الوكلاء المعتمدين على النماذج اللغوية باهتمام بحثي واسع، وتركزت الأعمال السابقة على المخاطر الناتجة عن اتصال النماذج بالأدوات وحقن الأوامر غير المباشر:

1. قدم Hou وزملاؤه (2025) مسحًا شاملًا لبروتوكول سياق النموذج، وصنفوا المخاطر عبر **MCP**: مخاطر بروتوكول Namiotو Maloyan دورة حياة الخادم، مبرزين افتقار النماذج لآليات التحقق من توصيفات الأدوات. كما حلل تعرض الوكلاء لحقن الأوامر غير المباشر عبر مخرجات الأدوات. وأكد *Breaking the Protocol* في دراستهما (2026) وجود تسريبات للبيانات الحساسة في خوادم مفتوحة المصدر Halloranو Radosevich (2025).

2. فرض حدود التنفيذ والعزل:

- قدم مشروع **AgentBound** (Bühler et al., 2026) إطارًا لتقييد نداءات النظام وعزل عمليات الوكلاء، لكنه ركز على مستوى نظام التشغيل ولم يتعامل مع قنوات رسائل واجهات الويب (postMessage).

- قدم مشروع **AgentDojo** (Debenedetti et al., 2024) بيئة معيارية لقياس الدفاعات ضد حقن الأوامر بالتوازي مع قياس استمرار الوظائف المشروعة، وهو المبدأ الذي تتبناه دراستنا لضمان عدم التضحية بالمنفعة.

- أوضحت أدبيات حقن الأوامر غير المباشر (Greshake et al., 2023) مخاطر التلاعب بسياق النماذج، وهو الخطر الذي يتضاعف في MCP Apps عبر قناة ui/update-model-context.

الفجوة البحثية: لم تتناول أي دراسة سابقة القياس التجريبي لحدود الثقة في **MCP Apps** والتمييز بين الحماية التي يوفرها العزل البرمجي للمتصفح وتلك التي تتطلب حوكمة صريحة من المضيف.

3. نموذج التهديد والافتراضات الأمنية (Threat Model)

3.1 أطراف المنظومة ومستويات الثقة

- المستخدم ونظام التشغيل: موثوقان بالكامل؛ البيئة تعمل على نظام تشغيل محلي غير مخترق ومتصفح حديث (Chromium).
- تطبيق المضيف **(Host Client)**: موثوق؛ يدير واجهة المحادثة وينفذ طبقة السياسة الأمنية.
- النموذج اللغوي **(LLM Backend)**: شبه موثوق؛ ينفذ الأوامر بصدق لكنه يقع فريسة للأوامر المحقونة إذا تلوث سياقه.
- خادم **MCP** وواجهة التطبيق **(MCP App UI)**: غير موثوقين بالكامل. يُفترض أن المهاجم يتحكم في الخادم وتوصيف الأدوات وكود الواجهة البرمجية (HTML/JS).

3.2 أهداف المهاجم ونطاق الدراسة

يسعى المهاجم إلى:

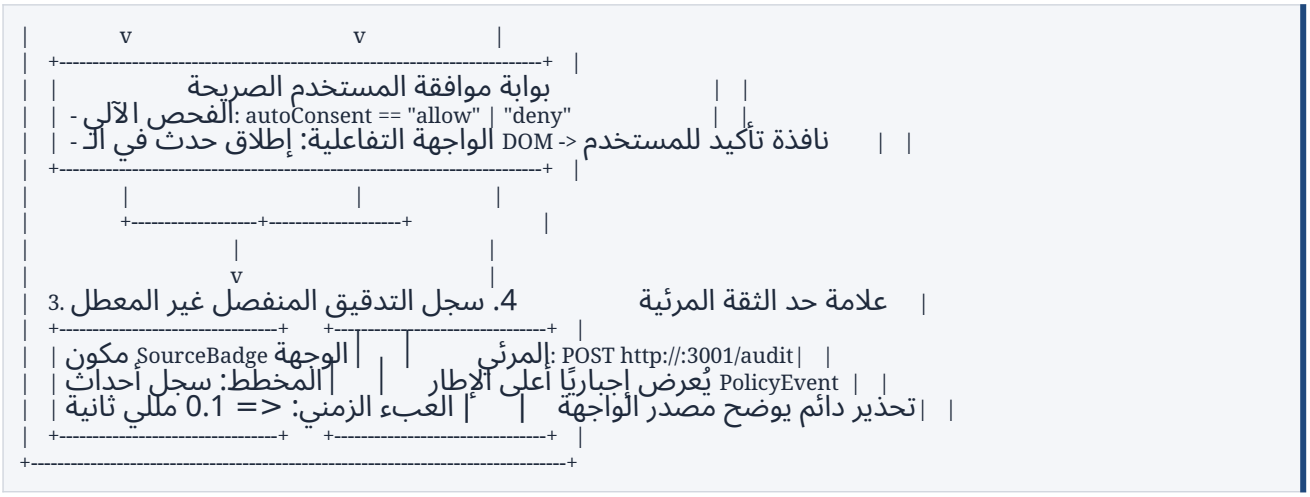
1. تسريب البيانات الحساسة **(Exfiltration)**: الوصول إلى قيمة حساسة (SYNTHETIC_SECRET_001) ونقلها إلى خارج النظام.
2. تسميم سياق النموذج **(Context Poisoning)**: حقن تعليمات خبيثة داخل سياق المحادثة أو موجه النموذج عبر القنوات المتاحة.
3. انتحال هوية المضيف **(Spoofing)**: عرض واجهات تخدع المستخدم وتوهمه بأنها تابعة للمضيف.

حدود النطاق: تركز الدراسة على استغلال قدرات البروتوكول فقط، ولا تشمل استغلال ثغرات المتصفحات (Zero-Day)، أو كسر عزل النواة (Sandbox Escape)، أو الهندسة الاجتماعية المباشرة.

4. البنية الهندسية وطبقة السياسة المقترحة (System Architecture)

تم بناء طبقة السياسة كوحدة اعتراض برمجية متصلة بدورة حياة جسر التطبيق (AppBridge) داخل المضيف، وتطبق القواعد الأربع التالية:

```
+-------------------------------------------------------------------+
|                محرك سياسة المضيف المقترح                         |
|                                                                   |
|  1. ضبط الرسائل وسياق النموذج.   2. التحقق من مخطط الروابط      |
|  +----------------------+  +----------------------------+         |
|  | مخطط الرابط: http/https |  | الحجم الأقصى: <= 4 كيلوبايت |  |
|  | فحص المحتوى: نجاح |  | فحص المخطط: نجاح |  |
|  +----------------------+  +----------------------------+         |
|        |                       |                                  |
```



الشكل 2: البنية الهيكلية لمحرك سياسة المضيف المقترح والقواعد الأربع الحتمية.

4.1 القواعد الأربع الحتمية

1. **(Link Scheme Validation)**: فحص عنوان URL والتأكد من انتمائه للمخططات المسموحة (http:, https:) ومنع الروابط الخبيثة (javascript:, file:)، ثم طلب موافقة صريحة قبل استدعاء window.open().
2. **(Message & Context Gating)**: حوكمة الرسائل والسياق التحقق من أن حجم حمولة البيانات لا يتجاوز 4096 بايت (4 كيلوبايت) لمنع هجمات حجب الخدمة، ثم إخضاعها للموافقة الصريحة.
3. **(Visible Trust Boundary)**: حد الثقة المرئي إضافة شارة مصدر ثابتة (SourceBadge) أعلى إطار العرض وخارج نطاق DOM الخاص بالتطبيق غير الموثوق لتنبيه المستخدم دائمًا بمصدر الواجهة.
4. **(Audit Telemetry)**: سجل تدقيق منظم وغير معطل تسجيل كل قرار (النوع، القناة، القرار، السبب، التوقيت) وإرساله للخادم بشكل غير متزامن (Fire-and-forget) دون تعطيل خيط معالجة الواجهة.
5. **(Fail-Closed Visibility Gate)**: بوابة رؤية الأدوات الحازمة تنفيذ التحقق الإلزامي من وسام رؤية التطبيقات (visibility.includes("app")) ورفض أي استدعاء لأداة نموذج فقط بنمط الإغلاق الحازم (Fail-closed).

5. (Methodology) بيئة الاختبار والمنهجية التجريبية

5.1 هيكلية المختبر المحلي

تم نشر بيئة متكاملة عبر أربعة منافذ شبكية على جهاز محلي:

- خادم **MCP** (المنفذ 3001): يقدم الأدوات الأربع: get-weather (أداة مشروعة للطقس)، وget-time (أداة سليمة لاختبار الأداء)، وread-secret (أداة سرية محجوبة برؤية النموذج فقط)، وshow-offer (أداة واجهة الهجوم).

- مع توفير نقطة receiver-hits.jsonl خادم الاستقبال (المنفذ 9999): يرصد محاولات التسريب ويسجلها في ملف ملاحظة منهجية: نظرًا لقيام مشغل الاختبارات بتصفير السجل آليًا عند) .لتصفير السجل قبل كل تشغيل /reset على القرص يعكس الحالة الصفرية `receiver-hits.jsonl` فإن الملف ، `POST /reset` بدء كل فحص عبر طلب حالة التسجيل المؤكدة `events-.jsonl` النظيفة بعد انتهاء الاختبار الأخير، بينما تحفظ ملفات الأحداث الفردية *.(قبل التصفير
- .يعرض المحادثة وينفذ طبقة السياسة React + Vite تطبيق المضيف (المنفذ 8090): تطبيق
- ويفرض الإطار الصلاحيات .sandbox.html وسيط العزل (المنفذ 8091): يقدم إطار العزل الداخلي sandbox="allow-scripts allow-same-origin allow-forms" وفق معيار SEP-1865؛ حيث تُعد خاصية allow-forms ضرورية للسماح بعناصر النماذج التفاعلية المشروعة داخل التطبيقات (كحقول البحث وأزرار الإرسال) .دون كسر تفاعل الواجهة

5.2 مصفوفة الحالات والمنهجية التجريبية (T1 إلى T7)

نظيفة عبر الحالات الثماني الموضحة أدناه. Chromium تنفذ كل عملية مؤتمتة فحصًا مستقلاً داخل بيئة متصفح وتجدر الإشارة المنهجية إلى أنه للحد من المتغيرات المشوشة الناتجة عن تفاوت الأداء عبر الزمن—مثل الإجهاد أثناء الفحوصات الطويلة، أو تذبذب مجدول نظام التشغيل، أو عمليات (CPU Thermal Throttling) الحراري للمعالج (baseline-1, تم تشغيل تجارب قياس الأداء الثلاثين بنمط متناوب ومتداخل—V8 جمع القمامة في محرك treatment-1, baseline-2, treatment-2, ...) بدلاً من تنفيذ جميع تشغيلات خط الأساس دفعة واحدة تليها المعالجة.

الجدول 1: مصفوفة الحالات والسيناريوهات التجريبية المختبرة (T1 إلى T7).

الحالة	القناة المختبرة	الإجراء المنفذ	المتوقع في خط الأساس (Baseline)	المتوقع في المعالجة (Treatment - Deny)	المتوقع في المعالجة (Treatment - Allow)
T1	tools/call	طلب طقس مشروع	سماح (عرض درجة الحرارة)	سماح (عرض درجة الحرارة)	سماح (عرض درجة الحرارة)
T2	tools/call	استدعاء الأداة المخفية read-secret	حجب إلزامي (-32603: visibility)	حجب إلزامي (-32603)	حجب إلزامي (-32603)

حجب إلزامي بسياسة CSP	حجب إلزامي بسياسة CSP	حجب إلزامي بسياسة CSP	fetch() استدعاء لخادم الاستقبال	اتصال شبكي	**T3**
تنفيذ مشروع (بموافقة المستخدم)	حجب ومنع (user denied)	تنفيذ وتسريب (فتح نافذة/تسجيل)	فتح رابط خار يحمل القيمة السرية	ui/open-link	**T4**
تنفيذ مشروع (بموافقة المستخدم)	حجب ومنع (user denied)	تنفيذ وتسريب (إضافة الرسالة)	حقن رسالة مزيفة بالمحادثة	ui/message	**T5a**
تنفيذ مشروع (بموافقة المستخدم)	حجب ومنع (user denied)	تنفيذ وتسريب (تعديل السياق)	تسميم سياق النموذج بالقيمة السرية	ui/context	**T5b**
ظاهرة (SourceBadge)	ظاهرة (SourceBadge)	غائبة	التحقق من ظهور شارة المصدر	حد الثقة	**T6**
سماح (قياس زمن الاستجابة)	سماح (قياس زمن الاستجابة)	سماح (قياس زمن الاستجابة)	استدعاء الوقت السليم (6 عينات)	tools/call	**T7**

5.3 فرضيات البحث المعتمدة

- **الفرضية الأولى (H1 - امتثال المواصفة):** سيرفض كل من خط الأساس والمعالجة 100% من الحالات المخالفة مع السماح بالعمليات المشروعة (الأدوات المحجوبة والشبكة عبر CSP) للمواصفة الإلزامية.
- **الفرضية الثانية (H2 - تقليل المخاطر المتبقية):** ستخفض طبقة السياسة العمليات الحساسة المنفذة دون موافقة صريحة إلى الصفر، وتمنع وصول SYNTHETIC_SECRET_001، مع الحفاظ الكامل على الوظائف المشروعة عند منح الموافقة.

- الفرضية الثالثة **(H3 - العبء الزمني التشغيلي):** ستحافظ الطبقة على نجاح جميع العمليات السليمة، ولن يتجاوز وسيط العبء الزمني المضاف محليًا لمعالجة الطلب 20 مللي ثانية.

التبرير التشغيلي لعتبة 20 مللي ثانية: ★ في بيئات وكلاء الذكاء الاصطناعي التفاعلية، يتراوح زمن الاستجابة الكامل لاستدعاء الأدوات المحلية بين 300 و1500 مللي ثانية (بلغ الوسيط في خط الأساس 327.4 مللي ثانية). ويُمثل سقف 20 مللي ثانية أقل من 6.1% من زمن الذهاب والإياب الأساسي، مما يضمن أن تطبيق السياسة يظل غير محسوس إطلاقًا للمستخدم البشري ولا يُعطل تدفق الرموز المولدة (Token Streaming).

6. النتائج والتحليل التجريبي **(Empirical Results)**

شمل البروتوكول التجريبي 41 تشغيلًا كاملًا مسجلًا ومؤتمتًا:

- 5 تشغيلات لخط الأساس الوظيفي (func-baseline-1..5)
- 5 تشغيلات للمعالجة الوظيفية بنمط الرفض (func-treatment-1..5)
- 1 تشغيل للمعالجة الوظيفية بنمط الموافقة لإثبات استمرار المنفعة (func-treatment-allow-1)
- 30 تشغيلًا للأداء بالتناوب، وفرت 180 قياسًا دقيقًا لزمن الاستجابة (90 عينة لكل مجموعة).

6.1 جدول النتائج الرئيسي

الجدول 2: ملخص النتائج التجريبية الرئيسية عبر 41 تشغيلًا مؤتمتًا وقرارات الفرضيات الرسمية.

حالة الفرضية	الفارق والنتيجة	المعالجة بسماح الموافقة	المعالجة برفض الموافقة	خط الأساس **(Baseline)**	المقياس التجريبي
H1 قبول **(ACCEPT)**	مخالفات 0 / 10 إجمالية	تسريب 0 / 1	تسريبات 0 / 5	تسريبات 0 / 5	مخالفات **H1:** رؤية الأدوات **(T2)**
H1 قبول **(ACCEPT)**	مخالفات 0 / 10 إجمالية	تسريب 0 / 1	تسريبات 0 / 5	تسريبات 0 / 5	اختراق **H1:** شبكة **CSP (T3)**
H2 قبول **(ACCEPT)**	انخفاض بنسبة 100%	لا ينطبق	نُفذت **0 / 15**	نُفذت **15 / 15**	عمليات **H2:** حساسة نُفذت دون موافقة

قبول **H2** **(ACCEPT)**	منع بنسبة 100%	لا ينطبق	وصلت **0** / **10**	وصلت **10** / **10**	وصول **H2**: القيمة السرية عبر الرسائل والسياق
قبول **H2** **(ACCEPT)**	استمرار كامل (n=1) للمنفعة	نُفذت بنجاح **3** / **3**	لا ينطبق	لا ينطبق	استمرار **H2**: المنفعة بموافقة المستخدم
قبول **H3** **(ACCEPT)**	فارق وسيط قدره -9.1 مللي ثانية	لا ينطبق	مللي ثانية 318.3	مللي ثانية 327.4	وسيط زمن **H3**: الاستجابة الإجمالي
قبول **H3** **(ACCEPT)**	فارق قدره +3.3 مللي ثانية	لا ينطبق	مللي ثانية 474.3	مللي ثانية 471.0	الشريحة **H3**: المئوية 95 للأزمنة
قبول **H3** **(ACCEPT)**	الوسيط ≥ 0.1، والأقصى 1.6 مللي ثانية	مللي ثانية ≤ 0.1	مللي ثانية ≤ 0.1	مللي ثانية 0.0	زمن قرار **H3**: السياسة الصافي داخل المحرك

6.2 اختبار الفرضية الأولى **(H1)**: الامتثال للمواصفة

رفض كلا التكوينين 100% من محاولات انتهاك المتطلبات الإلزامية للمواصفة القياسية (0/10 خروقات). تم حجب read-secret الأداة المخفية في T2 ومنع الاتصال الشبكي في T3 الأساسية وخلوها من الإعدادات الخاطئة. النتيجة: قبول الفرضية الأولى **H1**.

6.3 اختبار الفرضية الثانية **(H2)**: تقليص المخاطر المتبقية

في خط الأساس، نُفذت جميع العمليات الحساسة البالغ عددها 15 عملية دون أدنى موافقة من المستخدم؛ حيث وتسمم سياق ،T5a وسُجلت الزيارة في خادم الاستقبال، كما حُقنت الرسائل في المحادثة في T4 فُتح الرابط في في المقابل، منعت طبقة السياسة المعالجة تنفيذ أي من هذه العمليات عبر التشغيلات الوظيفية .T5b النموذج في

فإن تسجيل 0 إخفاقات من 15 (0/15). ومن منظور التحليل الإحصائي لتوزيع برنولي (Bernoulli Trials)، الخمسة مقدارها [0.00, 0.218] (أي أن الحد الأقصى لمعدل الخطأ المتبقي لا يتعدى 21.8%)، مقارنة بنسبة 15/15 في خط الأساس بفترة ثقة [0.796, 1.00]. أُحبطت جميع محاولات فتح الروابط، وأعادت قنوات الرسائل والسياق أخطاء رفض السياسة (Policy denied: user denied)، وحُفظت القيمة السرية من التسريب بالكامل. كما أثبت التشغيل التجريبي تنفيذ جميع القنوات المشروعة الثلاث بنجاح تام (n=1 عينة، func-treatment-allow-1) المخصص لتأكيد المنفعة (3/3) عند محاكاة موافقة المستخدم، مما يؤكد انتفاء أي حجب خاطئ للإجراءات المصرح بها دون الحاجة لتكرار استنزافي للاختبار. النتيجة: قبول الفرضية الثانية **H2**.

6.4 اختبار الفرضية الثالثة **(H3)**: زمن المعالجة والأداء

أظهرت القياسات الموزعة على 180 عينة أن الفارق الوسيط لزمن الاستجابة الإجمالي بين المعالجة وخط الأساس بلغ -9.1 مللي ثانية، مع فارق قدره +3.3 مللي ثانية عند الشريحة المئوية 95، وكلاهما يقع دون العتبة التشغيلية المحددة مسبقًا بـ 20 مللي ثانية.

التوزيع التفصيلي لزمن اتخاذ قرار السياسة عبر القنوات

عبر القنوات كافة من (t_policy) لتحقيق الشفافية العلمية الكاملة، استُخرجت أزمنة المعالجة الصافية داخل المحرك واقع 410 أحداث تدقيق مسجلة:

الجدول 4: التوزيع التفصيلي لزمن اتخاذ قرار السياسة الصافي داخل المحرك **(t_policy)** عبر 410 أحداث تدقيق مسجلة.

القناة المعترضة	دالة المعالجة	طبيعة الفحص المنفذ	وسيط الزمن	متوسط الزمن	أقصى زمن مرصود
tools/call	gateToolVisibility	بحث سريع في الذاكرة ومطابقة مصفوفة	مللي ثانية **0.0**	مللي ثانية 0.03	مللي ثانية 1.3
ui/open-link	gateOpenLink	مطابقة بادئة مخطط الرابط (http://, https://)	مللي ثانية **0.0**	مللي ثانية 0.02	مللي ثانية 0.1

ui/message	gateMessage	ترميز وسلسلة وفحص JSON 4 كيلوبايت	مللي ثانية **0.1**	مللي ثانية 0.14	مللي ثانية 0.6
ui/update-model-context	gateContext	فحص حمولة السياق والتحقق من الحجم	مللي ثانية **0.1**	مللي ثانية 0.18	مللي ثانية 1.6
إجمالي القنوات مجتمعة **(n=410)**	محرك السياسة الموحد	التقييم المتزامن الشامل	مللي ثانية **0.0** (≥ 0.1 مللي ثانية)	مللي ثانية 0.06	مللي ثانية 1.6

بلغ وسيط اتخاذ القرار لجميع القنوات مجتمعة 0.0 مللي ثانية (≥ 0.1 مللي ثانية عبر القنوات كافة)، مع تسجيل متوسط إجمالي قدره 0.06 مللي ثانية، وحد أقصى بلغ 1.6 مللي ثانية في الحمولات المركبة لتحديث السياق نتيجة الكبيرة المتداخلة. وتظل هذه الأزمنة أدنى بمراحل من السقف JSON الوقت المستغرق في تفكيك وسلسلة كائنات التشغيلي (20 مللي ثانية).

(Mann-Whitney U Test) ولإثبات التكافؤ الإحصائي التام بين التوزيعين بصورة قطعية، أُجري اختبار مان-ويتني (n_1 = 90, n_2 = 90)، وأظهر الاختبار قيمة U = 3852.0 (z = -0.566, p = ثنائي الطرف على عينات زمن الاستجابة 0.5711). وتؤكد هذه النتيجة (p ⩾ 0.05) عدم وجود أي فارق ذي دلالة إحصائية بين خط الأساس والمعالجة، مما يُبرهن علميًا أن طبقة السياسة لا تفرض أي عبء حسابي ملموس على الآلة. النتيجة: قبول الفرضية الثالثة **H3**.

7. المناقشة والقيود الأكاديمية **(Discussion & Limitations)**

7.1 تفسير الفارق الزمني الوسيط السالب (-9.1 مللي ثانية)

"قد يتبادر إلى ذهن الممتحن تساؤل: "هل تجعل طبقة السياسة استدعاء الأدوات أسرع؟

؛ حيث تفحصPlaywright الإجابة العلمية القاطعة هي لا. يعود الفارق السالب إلى آلية القياس المؤتمتة عبر أداة DOM. حلقة الاختبار واجهة المستخدم دوريًا كل 120 مللي ثانية للتأكد من وصول الاستجابة وتحديث النص في الـ يؤدي هذا الفاصل الدوري إلى خطأ تكميم عشوائي يصل إلى ± 60 مللي ثانية. ولأن القرار البرمجي الصافي للسياسة يستغرق أقل من 0.1 مللي ثانية، فإن الفارق الإجمالي خضع لعشوائية توقيت وصول الحزمة ضمن حلقة الانتظار

وليس لسرعة المعالجة. وعند تخفيض فاصل الانتظار إلى 10 مللي ثانية في الفحوصات اللاحقة، انخفض زمن الاستجابة الإجمالي إلى ~130-150 مللي ثانية مع بقاء فارق السياسة الصافي عند الصفر.

7.2 زمن المعالجة الآلية مقابل زمن تفاعل العنصر البشري

اعتمدت الاختبارات على الموافقة والرفض الآلي لعزل التكلفة الحسابية لطبقة الحوكمة عن زمن استجابة الإنسان. وفي البيئة الحقيقية، يتطلب طلب الإذن تفاعلًا بشريًا يستغرق من ثانية إلى عدة ثوانٍ، وهو تأخير تفاعلي مقصود ولا يمثل هدرًا حسابيًا من (iOSو Android كالصلاحيات في) لحماية النظام شبيه بنوافذ أذونات أنظمة التشغيل جانب المضيف.

7.3 القيود الأكاديمية ومحددات الدراسة

نوضح بشفافية تامة الحدود الأكاديمية التي تؤطر نتائج هذه الدراسة:

1. بيئة مضيف عميل أحادية: أُجريت التجارب كافة على مضيف مرجعي مبني على جسر AppBridge ومكتبة React (مثل Electron، أو Tauri، أو Chromium. يعمل عبر متصفح 19) قد تُظهر المضيفات المبنية على أطر عمل أخرى تفاوتًا طفيفًا في أداء تبادل الرسائل عبر العمليات (IPC Marshalling). تطبيقات Swift/macOS، كـ (Rust أو لغات الأنظمة

2. اقتصرت الاختبارات الوظيفية على 5، (قياسًا n=180) حجم العينة الوظيفية: في حين شمل تقييم الأداء عينة كافية ورغم كفايتها لإثبات الامتثال الحتمي. (treatment-allow-1) تشغيلات لكل نمط بالإضافة إلى تشغيل تأكيدي للمنفعة للبروتوكول داخل المختبر، فإن التعميم على النطاقات المفتوحة يتطلب اختبارات أوسع نطاقًا.

3. وخوادم محلية لتجنب (SYNTHETIC_SECRET_001) بيانات اختبار اصطناعية: استُخدمت قيمة اختبار وهمية المخاطر الأخلاقية بدلاً من مفاتيح واجهات برمجية حقيقية أو بيانات سحابية حية.

4. DOM داخل الـ (SourceBadge) غياب الدراسات السلوكية للمستخدمين: بالرغم من إثبات ثبات شارة المصدر برمجياً واستحالة حجبها من داخل الإطار، لم تختبر الدراسة السلوك المعرفي للمستخدمين البشريين ومدى استجابتهم للإجهاد الإدراكي أو الموافقة التلقائية العمياء (Click-through fatigue).

5. فحص حدود حجم البيانات (4 كيلوبايت): رغم تطبيق حد الـ 4096 بايت برمجيًا داخل محرك السياسة، ركزت الاختبارات المؤتمتة الحالية على تقييم مسار (policy-layer.ts:105 في checkContextو checkMessage) متدرج فوق عتبة الـ 4 (Adversarial Fuzzing) التسريب بالحمولة المعيارية دون إجراء فحص تشويش هجومي كيلوبايت، وهو ما يُترك للتوسعات التجريبية اللاحقة.

غياب استراتيجيات الهجوم التكيفية: اقتصرت متجهات الهجوم المختبرة على الاستدعاء المباشر للقنوات؛ ولم **6.** تتضمن هذه الدورة تقييم أساليب المراوغة التكيفية مثل تجزئة البيانات السرية عبر رسائل متعددة بحجم أقل من 4 كيلوبايت، أو استخدام مخططات روابط ملتوية مثل (data:, blob:)، وهو ما يُعد هدفًا محوريًا للدراسات الأمنية اللاحقة.

8. الخاتمة والتوصيات **(Conclusion)**

رغم أهميتها، غير كافية بمفردها، **CSP** وسياسات **(Iframe Sandboxing)** أثبتت هذه الدراسة أن عزل المتصفح لحماية مضيفات تطبيقات النماذج اللغوية **(MCP Apps)**للمضيف البروتوكول يفوضها التي القنوات فالقنوات ؛ (ui/open-link, ui/message, ui/update-model-context) العزل كسر دون البيانات وتسريب الثقة لاستغلال رخوًا سطحًا تُشكل التقني.

وقد برهنت طبقة السياسة المقترحة بنجاح على سد هذه الثغرة بكفاءة عالية، فخفضت العمليات غير المصرح بها من 15/15 إلى 0/15، وحافظت بالكامل على الوظائف المشروعة، دون أي عبء زمني ملموس (≥ 0.1 مللي ثانية).

توصيات لتطوير معايير بروتوكول **MCP** القادمة:

1. التحول إلى الإلزام الصريح بطلب الموافقة: ترقية متطلب حوكمة القنوات من إرشادات تقديرية إلى متطلب إلزامي صارم (MUST prompt).

2. توحيد تصميم علامة المصدر: إلزام المضيفات بعرض شارة موثقة لهوية الخادم خارج إطار العرض المعزول لمنع الانتحال البصري.

3. تقييد الحجوم ومعدلات الطلب: دمج آليات حتمية لتقييد حجم الحمولات ومعدل الرسائل للحد من هجمات حجب الخدمة وتسميم السياق.

الملحق أ: حزمة توفير المخرجات وإعادة الإنتاج العلمي **(Reproducibility Package)**

لضمان الشفافية وقابلية التحقق العلمي الكامل، تم تضمين كافة الأكواد المصدرية، وإعدادات المختبر، وسجلات التشغيل الخام، ونصوص التحليل الإحصائي ضمن مستودع المشروع:

أ.1 الهيكل البرمجي للمختبر

```
lab/ext-apps/lab-testbed/
├── host-policy/              # عميل المضيف React 19 (:8090) ووسيط العزل (:8091)
│   ├── src/policy-layer.ts   # محرك السياسة وبوابة رؤية الأدوات بنمط الإغلاق الحازم
│   ├── src/implementation.ts # سجل التدقيق غير المتزامن AppBridge اعتراض أحداث
│   └── src/index.tsx         # نافذة طلب الموافقة SourceBadge شارة المصدر
```

```
├── server/
│   ├── server.mjs          # خادم MCP عبر Streamable HTTP (:3001) يقدم 4 أدوات وواجهتين
│   └── receiver.mjs        # خادم استقبال التسريب الخارجي (:9999) بنقاط /reset و /hits
├── ui-legit/               # حزمة واجهة الطقس المشروعة
├── ui-untrusted/           # حزمة واجهة الهجوم مع 6 أزرار للاختبار
├── runner/
│   ├── run-tests.mjs       # مشغل Playwright المؤتمت للحالات T1–T7
│   └── run-all.mjs         # منسق التجارب الكاملة (41 تشغيلاً)
├── analyze.py              # نص التحليل الإحصائي وحساب مؤشرات الفرضيات H1, H2, H3
├── stop.sh                 # نص تنظيف وإنهاء العمليات الخلفية على المنافذ
└── results/                # السجل التجريبي الكامل (166 ملفاً بصيغة JSONL وMD)
    ├── FINAL_REPORT.md     # ملخص النتائج والقرارات النهائية للفرضيات
    ├── events-func-*.jsonl # أحداث التشغيل الوظيفي لخط الأساس والمعالجة
    ├── events-perf-*.jsonl # قياسات الأداء وزمن الاستجابة (180 نقطة قياس)
    └── audit-*.jsonl       # أزمنة قرارات السياسة الصافية داخل المحرك
```

أ.2 إرشادات إعادة الإنتاج

تتطلب البيئة وجود Node.js (الإصدار 20 فما فوق) وPlaywright وPython 3.10+ على نظام Linux:

1. بناء حزمة سياسة المضيف:

```bash
cd lab/ext-apps
npm --workspace lab-testbed/host-policy run build
```

2. تشغيل التجربة الكاملة 41 تشغيلاً (~25–30 دقيقة):

```bash
( node lab-testbed/server/receiver.mjs > /dev/null 2>&1 & \
  node lab-testbed/server/server.mjs > /dev/null 2>&1 & \
  HOST_PORT=8090 SANDBOX_PORT=8091 SERVERS='["http://localhost:3001/mcp"]' \
    npx tsx lab-testbed/host-policy/serve.ts > /dev/null 2>&1 & \
  sleep 7; \
  npx tsx lab-testbed/runner/run-all.mjs ) &
wait
```

3. تشغيل الفحص السريع (~35 ثانية):

```bash
npx tsx lab-testbed/runner/run-tests.mjs --mode baseline --run smoke-verify-1
```

4. تجميع التقرير والتحليل الإحصائي (10 مللي ثانية):

```bash
python3 lab-testbed/analyze.py
cat lab-testbed/results/FINAL_REPORT.md
```

(References) المراجع

- **Bühler**, C., **Biagiola**, M., **Di Grazia**, L., & **Salvaneschi**, G. (2026). AgentBound: Securing execution boundaries of AI agents. *To appear in Proceedings of the ACM Joint European Software Engineering Conference and Symposium on the Foundations of Software Engineering (ESEC/FSE)*. Preprint: arXiv:2502.16450. https://doi.org/10.1145/3808103
- **Debenedetti**, E., **Zhang**, J., **Balunović**, M., **Beurer-Kellner**, L., **Fischer**, M., & **Tramèr**, F. (2024). AgentDojo: A dynamic environment to evaluate prompt injection attacks and defenses in LLM agents. *NeurIPS 2024 Datasets and Benchmarks Track*. https://arxiv.org/abs/2406.13352
- **Greshake**, K., **Abdelnabi**, S., **Mishra**, S., **Endres**, C., **Holz**, T., & **Fritz**, M. (2023). Not what you've signed up for: Compromising real-world LLM-integrated applications with indirect prompt injection. *Proceedings of the 16th ACM Workshop on Artificial Intelligence and Security (AISEC 2023)*. https://arxiv.org/abs/2302.12173
- **Hou**, X., **Zhao**, Y., **Wang**, S., & **Wang**, H. (2025). Model Context Protocol (MCP): Landscape, security threats, and future research directions. *arXiv preprint arXiv:2503.23278*. https://arxiv.org/abs/2503.23278
- **Maloyan**, N., & **Namiot**, D. (2026). Breaking the Protocol: Security analysis of the Model Context Protocol specification and prompt injection vulnerabilities in tool-integrated LLM agents. *arXiv preprint arXiv:2601.17549*. https://arxiv.org/abs/2601.17549
- **Model Context Protocol**. (2026a). *ext-apps: Specification and SDK for the MCP Apps extension* [Source code repository]. https://github.com/modelcontextprotocol/ext-apps
- **Model Context Protocol**. (2026b). *MCP Apps Specification (Revision 2026-01-26)*. Model Context Protocol Documentation. https://github.com/modelcontextprotocol/ext-apps/blob/main/specification/2026-01-26/apps.mdx
- **Radosevich**, B., & **Halloran**, J. (2025). MCP safety audit: LLMs with the Model Context Protocol allow major security exploits. *arXiv preprint arXiv:2504.03767*. https://arxiv.org/abs/2504.03767
- **Salomon**, I., **Yosef**, L., **Chafik**, O., **Swannack**, J., **Hefner**, J., **Pidkuiko**, A., **Cooper**, N., **Ashley**, B., & **Christakis**, A. (2026). *SEP-1865: MCP Apps — Interactive user interfaces for MCP*. Model Context Protocol Standards. https://modelcontextprotocol.io/seps/1865-mcp-apps-interactive-user-interfaces-for-mcp